

Résumé

Dans le cadre de mon stage d'initiation à l'École Nationale des Sciences Appliquées de Tétouan, j'ai intégré la société Amendis, filiale du groupe Veolia, spécialisée dans la gestion des services d'eau et d'électricité. L'entreprise est confrontée à une problématique récurrente : la fraude dans la consommation, qui engendre des pertes économiques considérables et complique la gestion des réseaux. L'objectif principal de mon stage était de contribuer au développement d'un système hybride de détection des fraudes, combinant des modèles de machine learning avec des règles métiers issues de l'expertise des professionnels de terrain.

La démarche adoptée a consisté, dans un premier temps, à analyser et préparer les données disponibles, comprenant notamment les historiques de consommation et les profils clients. Ensuite, plusieurs modèles de machine learning ont été explorés afin d'identifier les comportements atypiques. Parallèlement, des règles métier ont été définies en collaboration avec les experts de l'entreprise pour prendre en compte des cas spécifiques que les algorithmes seuls ne pouvaient détecter. L'intégration de ces deux approches a permis de concevoir un système plus robuste et adapté au contexte opérationnel d'Amendis.

Ce stage m'a permis d'acquérir des compétences techniques en traitement de données et en apprentissage automatique, mais également de développer une compréhension pratique des enjeux liés à la fraude et à la gestion de l'énergie. Enfin, cette expérience m'a offert une première immersion dans le milieu professionnel, en renforçant à la fois mes aptitudes techniques et mon sens de la collaboration.

Table des matières

Résumé	i
1 Introduction Générale	1
1.1 Contexte général	1
1.2 Problématique	1
1.3 Objectifs du stage	2
2 Présentation de l'Entreprise	3
2.1 Le Groupe Veolia	3
2.2 Amendis – Filiale marocaine	3
3 Approche Méthodologique et Système Hybride de Détection de Fraudes	5
3.1 Préparation des données	5
3.1.1 Sources de données	5
3.1.2 Prétraitement des données	6
3.1.3 Feature Engineering	6
3.2 Statistiques et Features de Consommation	6
3.2.1 Statistiques classiques (niveau & dispersion)	6
3.2.2 Tendances et dynamique	7
3.2.3 Distribution et forme de la série	7
3.2.4 Règles métier transformées en features	7
3.3 Création d'un dataset fiable – PU Learning	8
3.4 Partition temporelle et modélisation – Stacking	8
3.4.1 Split temporel	9
3.4.2 Modélisation avec Stacking	9
3.5 Gestion du déséquilibre des classes	10
1.1 Règle 1 – Chute Brutale de Consommation	11
1.2 Règle 2 – Baisse Continue de Consommation	12
1.3 Règle 3 – Absence Totale de Consommation	13
1.4 Règle 4 – Régularité Extrême (Compteur Possiblement Bloqué)	13
3.6 Fusion Hybride (Machine Learning + Règles)	14
2 Résultats du système	16
2.1 Évaluation de la performance	16
3 Conclusion et Perspectives	17
3.1 Synthèse des travaux	17
3.2 Perspectives d'amélioration	18

Chapitre 1

Introduction Générale

1.1 Contexte général

L'eau et l'électricité constituent des ressources vitales, indispensables au développement économique et social. Leur gestion optimale représente un défi majeur pour les sociétés de distribution, confrontées à des enjeux de rentabilité, de durabilité et de satisfaction client. Dans ce contexte, la fraude liée à la consommation constitue une problématique universelle, qui touche aussi bien les pays développés que les pays émergents. Les pertes engendrées ne se limitent pas aux aspects financiers ; elles compromettent également l'équité entre les usagers et peuvent fragiliser les investissements en infrastructures.

L'évolution récente des technologies numériques et de l'intelligence artificielle offre cependant de nouvelles perspectives pour relever ce défi. Les méthodes de machine learning, en particulier, permettent d'exploiter les grandes quantités de données générées par les systèmes de comptage afin d'identifier des comportements suspects. Ces approches, lorsqu'elles sont enrichies par l'expertise métier, deviennent des outils puissants pour renforcer la fiabilité des processus de contrôle et de supervision.

1.2 Problématique

La fraude de consommation d'eau et d'électricité se manifeste sous différentes formes : manipulations techniques des compteurs, branchements illégaux, ou encore anomalies commerciales dans la facturation. Ces pratiques engendrent des pertes considérables pour les sociétés de distribution et compliquent la gestion équilibrée des réseaux.

Chez Amendis, filiale du groupe Veolia, cette problématique est particulièrement critique, car elle impacte directement la performance économique et la qualité du service rendu aux clients. Face à la complexité et à la diversité des fraudes, une approche purement manuelle ou exclusivement statistique reste insuffisante. Il devient alors nécessaire d'exploiter les technologies récentes afin d'améliorer la détection des cas frauduleux.

1.3 Objectifs du stage

Le stage d'initiation que j'ai effectué chez Amendis s'inscrit dans cette problématique. Il avait pour objectif principal de concevoir une première version d'un système de détection de fraude basé sur une approche hybride. Plus précisément, ce travail consistait à :

- Explorer et analyser les données de consommation mises à disposition par l'entreprise.
- Mettre en œuvre des modèles de machine learning capables de distinguer les comportements normaux des comportements suspects.
- Collaborer avec les experts métier afin d'intégrer des règles pratiques et adaptées au terrain.
- Proposer une architecture préliminaire combinant ces deux approches et permettant d'améliorer la fiabilité de la détection.

Au-delà de l'aspect technique, le stage visait également à développer mes compétences professionnelles en matière de gestion de projet, de communication et de travail collaboratif dans un environnement industriel.

Chapitre 2

Présentation de l'Entreprise

2.1 Le Groupe Veolia

Fondé en 1853 sous le nom de Compagnie Générale des Eaux, Veolia est aujourd'hui un leader mondial dans la gestion des ressources. L'entreprise a développé une expertise reconnue dans la gestion de l'eau, des déchets et de l'énergie, tout en s'inscrivant dans une logique de transition écologique et d'adaptation aux enjeux environnementaux et technologiques.

Au fil de son histoire, Veolia a su se diversifier et intégrer des solutions innovantes, telles que le traitement des eaux usées industrielles, la valorisation énergétique des déchets, et le développement de services connectés pour la surveillance et l'optimisation des infrastructures.

Veolia opère sur cinq continents, avec environ 215 000 employés en 2024. Ses activités incluent :

- la gestion du cycle complet de l'eau (production, distribution et assainissement) ;
- le traitement et la valorisation des déchets solides et liquides ;
- les solutions énergétiques pour les industries et collectivités, incluant l'efficacité énergétique et les énergies renouvelables.

L'entreprise combine une forte présence locale via un réseau de filiales et de partenariats avec une expertise globale, lui permettant de s'adapter aux spécificités réglementaires et environnementales de chaque pays.

2.2 Amendis – Filiale marocaine

Amendis, filiale marocaine de Veolia, est un acteur majeur dans le secteur des services environnementaux au Maroc. Elle assure la distribution d'eau potable, l'assainissement et la collecte des déchets dans plusieurs villes, notamment Tanger et Tétouan.

La société joue un rôle clé dans la modernisation des infrastructures urbaines et l'amélioration de la qualité des services publics environnementaux. Elle adopte des technologies avancées pour la surveillance des réseaux, la détection de fuites et la gestion intelligente de la consommation, contribuant à la durabilité et à l'efficacité du service.

Les missions principales d'Amendis comprennent :

- la fourniture d'eau potable fiable et la gestion des services d'assainissement pour les collectivités et les industries ;
- la gestion efficace des déchets solides et liquides et l'optimisation des ressources naturelles ;
- la réduction de l'impact environnemental, le soutien aux initiatives locales de développement durable, et la sensibilisation des citoyens à l'usage responsable des ressources.

Amendis intègre également des pratiques innovantes de suivi et de maintenance, telles que la télésurveillance des installations, l'analyse des données de consommation, et des programmes de prévention des fraudes et pertes, afin d'assurer un service performant et durable pour ses clients.

Chapitre 3

Approche Méthodologique et Système Hybride de Détection de Fraudes

L'objectif principal de ce projet était donc de développer un système capable de détecter efficacement les comportements frauduleux à partir des historiques de consommation, tout en limitant les erreurs de classification qui pourraient générer des coûts inutiles. D'un point de vue technique, le projet visait à concevoir un système robuste et fiable, capable de produire des prédictions précises sur l'état de chaque client. L'un des aspects les plus critiques était la précision du modèle : un nombre élevé de faux positifs entraînerait des interventions coûteuses et superflues, ce qui aurait un impact économique significatif pour l'entreprise. Le rappel était également important afin de ne pas passer à côté de fraudes avérées, mais il était considéré secondaire par rapport à la précision. Ainsi, le système devait gérer le *trade-off précision/rappel*, en trouvant un équilibre optimal entre ces deux métriques, tout en restant stable et exploitable pour un déploiement pratique.

3.1 Préparation des données

3.1.1 Sources de données

Le projet s'est appuyé sur deux sources de données principales. La première contenait les historiques de consommation des clients, incluant le numéro de contrat, le numéro de client et les consommations mensuelles sur une période de 30 mois, allant de janvier 2023 à juin 2025. La deuxième source correspondait à un fichier recensant toutes les fraudes déjà détectées par l'entreprise Amendis.

Afin de créer un dataset exploitable pour le machine learning, ces deux fichiers ont été fusionnés. Le fichier final permet de relier chaque client et contrat à son historique de consommation et d'indiquer si des fraudes avaient été identifiées durant la période considérée. Cette fusion a permis d'obtenir une vision complète et cohérente, indispensable pour la construction de modèles fiables.

3.1.2 Prétraitement des données

Le prétraitement a constitué une étape cruciale pour assurer la qualité des données et maximiser la performance des modèles. Les valeurs manquantes ont été traitées avec soin : lorsque des clients présentaient un maximum de cinq mois de consommation manquants, une interpolation linéaire a été appliquée pour compléter les données. En revanche, les clients dont les données manquaient sur plus de cinq mois ont été supprimés, afin d'éviter d'introduire un biais qui pourrait dégrader l'apprentissage du modèle.

La normalisation des données a également été appliquée. Cette étape consiste à ajuster l'échelle des différentes variables afin de les rendre comparables. Elle est particulièrement importante pour les algorithmes de machine learning, car elle améliore la convergence des modèles et garantit que les coefficients attribués à chaque variable reflètent correctement leur influence, plutôt que d'être biaisés par des différences d'échelle.

3.1.3 Feature Engineering

Le Feature Engineering a été au cœur de ce projet, car la performance du modèle dépend fortement de la qualité et de la pertinence des variables utilisées. L'objectif était de créer des features robustes, explicables et adaptées aux méthodes de machine learning employées.

Les features ont été conçues pour capturer plusieurs aspects de la consommation : les statistiques classiques (niveau moyen, volatilité, dispersion), les tendances et dynamiques (pentes, variations sur différentes périodes, anomalies ponctuelles), la distribution et la forme des séries temporelles (asymétrie, kurtosis, variations saisonnières), ainsi que des transformations des règles métier directement dérivées de l'expertise terrain. Ces dernières permettent de quantifier des comportements suspects identifiés par l'expérience des agents de terrain, comme les chutes brutales ou les périodes de consommation quasi nulle.

Des tableaux détaillés présentent chacune de ces features, accompagnées de leurs formules et explications, offrant une vue claire de l'ensemble des variables utilisées dans la modélisation.

3.2 Statistiques et Features de Consommation

3.2.1 Statistiques classiques (niveau & dispersion)

Nom	Formule / Description	Explication
Moyenne 30 mois du client	$\mu = \frac{1}{30} \sum_{i=1}^{30} x_i$	Niveau moyen de consommation sur la période longue
Écart-type 30 mois	$\sigma = \sqrt{\frac{1}{30} \sum_{i=1}^{30} (x_i - \mu)^2}$	Volatilité globale du client
Coefficient de variation 30 mois	$CV = \frac{\sigma}{\mu}$	Dispersion relative (faible CV → consommation stable)
Min 30 mois	$\min(x_1, \dots, x_{30})$	Détecte mois très bas ou anomalies
Max 30 mois	$\max(x_1, \dots, x_{30})$	Détecte pics de consommation

TABLE 3.1 – Statistiques classiques

3.2.2 Tendances et dynamique

Nom	Formule / Description	Explication
Slope 30 mois	Pente de régression linéaire sur 30 mois	Tendance long terme : baisse ou hausse continue
Delta_last12_vs_prev18	Moyenne 12 derniers mois / Moyenne 18 mois précédents	Variation relative récente vs passé
Delta_last3_vs_prev3	Moyenne 3 derniers mois / Moyenne 3 mois précédents	Détection chute/glisement court terme
MaxDrop	Plus grande baisse mensuelle relative sur l'historique	Capture l'anomalie la plus sévère
DropCount	Nombre de mois avec chute $\geq 30\%$ vs baseline	Fréquence des baisses brutales
SpikeCount	Nombre de mois avec consommation $> \mu + 2\sigma$	Repère pics anormaux

TABLE 3.2 – Tendances et dynamique

3.2.3 Distribution et forme de la série

Nom	Formule / Description	Explication
Skewness_30m	$Skewness = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3}{\sigma^3}$	Détecte valeurs extrêmes / biais
Kurtosis_30m	$Kurtosis = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^4}{\sigma^4}$	Queue lourde ou pics $\rightarrow$ anomalies
SeasonalRange	$\max(mois\ similaires) - \min(mois\ similaires)$	Repère absence de variation saisonnière ou anomalies saisonnières

TABLE 3.3 – Distribution et forme de la série

3.2.4 Règles métier transformées en features

Règles utilisées : R1, R3, R4 Chaque feature capture fréquence, intensité et extrême si pertinent.

R1 – Chute Brutale :

Nom	Description	Explication
R1_nDrops	Nombre de mois où chute $\geq 30\%$ vs baseline	Fréquence des baisses brutales sur l'historique
R1_avgDrop	Moyenne des baisses relatives sur ces mois	Intensité moyenne des chutes
R1_maxDrop	Plus grande chute relative observée	Capture l'anomalie la plus sévère

TABLE 3.4 – R1 – Chute brutale

R3 – Baisse Continue :

Nom	Description	Explication
R3_nPeriods	Nombre de périodes consécutives (≥ 3 mois ou ≥ 2 années) en baisse	Fréquence de la baisse persistante
R3_avgDecline	Moyenne des baisses relatives dans ces périodes	Intensité moyenne de la baisse structurelle

TABLE 3.5 – R3 – Baisse continue

R4 – Consommation Nulle / Régularité Extrême :

Nom	Description	Explication
R4_nZeroMonths	Nombre de mois avec consommation ≤ 5 kWh	Fréquence des mois suspects
R4_avgZero	Moyenne des consommations très faibles	Intensité de la consommation quasi nulle
R4_minMaxRange	Écart max – min sur fenêtre glissante 6 mois	Détecte absence de variation saisonnière, compteur bloqué

TABLE 3.6 – R4 – Consommation nulle / régularité extrême

3.3 Création d'un dataset fiable – PU Learning

Dans le cadre de ce projet, un problème central est que les labels négatifs ne sont pas totalement fiables. En effet, certains clients considérés comme «non fraudeurs» par Amendis pourraient en réalité avoir commis une fraude qui n'a pas encore été détectée. Entraîner un modèle directement sur ces labels pourrait introduire un biais majeur, réduisant considérablement la capacité du modèle à identifier de nouvelles fraudes.

Pour contourner ce problème, la méthode Positive-Unlabeled Learning (PU Learning)¹ a été appliquée afin d'identifier des négatifs fiables avant l'entraînement des modèles finaux.

Le processus est le suivant :

- Un modèle Random Forest est entraîné uniquement sur les positifs confirmés (fraudes détectées) et un échantillon de clients non labellisés (dont le statut de fraude est incertain).
- Ce modèle sert à estimer la probabilité de fraude pour chaque client non labellisé.
- Les clients ayant les probabilités les plus faibles sont alors considérés comme des négatifs fiables.
- Le dataset final est constitué en combinant ces négatifs fiables avec les positifs confirmés, garantissant ainsi un jeu de données fiable et représentatif pour l'entraînement des modèles ultérieurs.

Cette approche permet de nettoyer les labels incertains avant l'entraînement, assurant que le modèle apprenne des schémas représentatifs de la fraude sans être biaisé.

3.4 Partition temporelle et modélisation – Stacking

Une fois le dataset fiable constitué, l'étape suivante consiste à préparer les données pour l'entraînement et à construire le système de prédiction.

1. Le Positive-Unlabeled Learning (PU Learning) est une approche d'apprentissage supervisé utilisée lorsque seules certaines instances positives sont étiquetées et que le reste des données est non étiqueté. L'objectif est de construire un modèle capable d'identifier correctement les positifs tout en estimant quels exemples non étiquetés peuvent être considérés comme négatifs fiables, afin de réduire le biais lié aux labels incertains.

3.4.1 Split temporel

Le split temporel est essentiel pour éviter la fuite de données (data leakage) et le surapprentissage.

La division retenue :

- Train : 70 % des mois les plus anciens
- Validation : 15 % des mois suivants
- Test : 15 % des mois les plus récents

Cela permet de reproduire un contexte réel, où le modèle est testé sur des données futures qu'il n'a jamais vues.

3.4.2 Modélisation avec Stacking

Pour améliorer la capacité prédictive et la robustesse du système, une **approche de stacking** a été adoptée. Le stacking consiste à **combiner plusieurs modèles de machine learning** pour tirer parti de leurs forces complémentaires et réduire le risque que l'erreur d'un modèle se répercute sur le résultat final. L'idée centrale est que différents algorithmes apprennent des aspects différents des données : certains capturent des relations linéaires, d'autres des interactions complexes ou des comportements non linéaires.

Modèles de base : Random Forest, XGBoost et LightGBM

- **Random Forest** est un ensemble d'arbres de décision construits sur des sous-échantillons aléatoires des données et des variables. Chaque arbre fait une prédiction et le vote majoritaire détermine la sortie finale. Ce modèle est particulièrement efficace pour gérer des données bruitées et peut intégrer une pondération des classes (`class_weight='balanced'`) pour tenir compte du déséquilibre entre fraudes et non-fraudes. Dans notre projet, nous avons utilisé **200 arbres** (`n_estimators=200`) avec une profondeur illimitée pour permettre à chaque arbre de capturer toutes les interactions possibles dans les données.
- **XGBoost** est un modèle de gradient boosting, qui construit les arbres séquentiellement, chaque arbre corrigeant les erreurs du précédent. Nous avons fixé `learning_rate=0.05` pour un apprentissage progressif et `max_depth=6` pour éviter que les arbres ne surapprennent le bruit. Le paramètre `scale_pos_weight` a été utilisé pour ajuster le déséquilibre des classes.
- **LightGBM** est un autre modèle de gradient boosting optimisé pour la vitesse et l'efficacité. Il utilise `num_leaves=31` pour contrôler la complexité des arbres et `learning_rate=0.05`, tout en appliquant `scale_pos_weight` pour gérer le déséquilibre.

Le **Méta-modèle (régression logistique)** reçoit en entrée les prédictions des modèles de base et les combine pour produire un **score final interprétable**. La régression logistique permet d'attribuer un **poids optimal à chaque modèle**, en fonction de sa performance sur le jeu de validation, et de produire un résultat calibré. Nous avons utilisé **C=1.0, penalty L2 et solver liblinear**, des paramètres standards assurant stabilité et régularisation.

Validation et prévention du surapprentissage :

- La **cross-validation temporelle** (time-series cross-validation) avec fenêtres progressives garantit que le modèle est évalué sur des périodes ultérieures aux périodes d'entraînement, respectant la chronologie et évitant la fuite d'information.

- Le **early stopping** sur XGBoost et LightGBM permet d'arrêter l'entraînement si le modèle commence à surapprendre le bruit des données.
- La **surveillance du gap train/validation**, combinée à la régularisation et à l'ajustement des hyperparamètres, assure que le modèle généralise correctement sur de nouvelles données.

Cette approche garantit que le système **exploitera pleinement l'information présente dans les historiques de consommation**, tout en produisant des prédictions **robustes et généralisables**, essentielles pour réduire les fausses alertes et détecter efficacement les fraudes.

3.5 Gestion du déséquilibre des classes

Même après la sélection des négatifs fiables, les classes restent fortement déséquilibrées, avec une minorité de fraudes.

Stratégies mises en place :

- **Arbres avec pondération des classes** (`class_weight='balanced'`) pour que les fraudes soient correctement prises en compte.
- **Sur-échantillonnage synthétique** : SMOTE et ADASYN sur l'ensemble d'entraînement uniquement
 - Permet de générer artificiellement des exemples minoritaires
 - Évite toute fuite sur validation ou test

Ces mesures améliorent la **capacité du modèle à détecter les fraudes**, tout en conservant la fiabilité des prédictions.

Règles métiers

1.1 Règle 1 – Chute Brutale de Consommation

Détecter une diminution anormale et brutale de la consommation électrique, susceptible d'indiquer une fraude ou une manipulation du compteur.

La règle peut être activée par l'un ou l'autre des deux scénarios suivants :

- **Scénario 1** : Comparaison interannuelle (même mois en 2025 vs moyenne 2023–2024)
- **Scénario 2** : Comparaison glissante sur 6 mois (3 derniers mois vs 3 précédents)

La règle est activée si au moins un des deux scénarios détecte une baisse de consommation $\geq 30\%$. Un bonus si les deux scénarios sont simultanément déclenchés.

Scénario 1 – Comparaison Interannuelle sur Mois Fixe

Condition : Comparer la consommation du mois M en 2025 à la moyenne du même mois M en 2024 et 2023.

Formule :

$$Ratio = \frac{Consommation_{2025,M}}{\frac{Consommation_{2024,M} + Consommation_{2023,M}}{2}}$$

Déclenchement : Si la consommation en 2025 est inférieure ou égale à 70% de la moyenne des deux années précédentes pour le même mois. Cela correspond à une diminution $\geq 30\%$, ce qui déclenche le scénario.

Scénario 2 – Comparaison Glissante sur 6 Mois

Condition : Comparer la moyenne des 3 derniers mois disponibles à celle des 3 mois précédents immédiatement.

Formule :

$$Ratio = \frac{Moyennedes3derniersmois}{Moyennedes3moisprcdents}$$

Déclenchement : Si la baisse est supérieure ou égale à 30%, ce scénario est déclenché.

Exemple :

- Jan–Fév–Mars : [160, 175, 170] → Moyenne = 168
- Avril–Mai–Juin : [120, 125, 110] → Moyenne = 118.3
- Ratio : $118.3/168 \approx 0.70$ → Règle activée (seuil atteint)

1.2 Règle 2 – Baisse Continue de Consommation

Identifier une réduction anormale et globale de la consommation d'un client d'une année à l'autre, suggérant une fraude persistante ou une manipulation continue du compteur.

Cette règle repose sur deux scénarios de comparaison annuelle :

- **Scénario 1** : Comparaison globale 2023 vs 2024
- **Scénario 2** : Comparaison partielle 2024 vs 2025 (selon les mois disponibles)

La règle est activée si au moins un des deux scénarios détecte une baisse $\geq 30\%$. Bonus si les deux sont déclenchés.

Scénario 1 – Baisse Moyenne Année Pleine (2023 vs 2024)

Condition : Comparer la moyenne mensuelle de l'ensemble de l'année 2024 avec celle de 2023.

Formule :

$$Ratio = \frac{Moyennemensuelle_{2024}}{Moyennemensuelle_{2023}}$$

Déclenchement : Si la consommation moyenne mensuelle en 2024 est inférieure ou égale à 70% de celle de 2023. Cela signifie une diminution de 30% ou plus.

Scénario 2 – Baisse Moyenne 2025 (vs mêmes mois de 2024)

Condition : Comparer la moyenne des mois disponibles en 2025 avec la moyenne des mêmes mois en 2024.

Formule :

$$Ratio = \frac{Moyennedesmoisdisponibles_{2025}}{Moyennedesmmesmois_{2024}}$$

Déclenchement : Si la moyenne en 2025 est inférieure ou égale à 70% de la moyenne des mêmes mois en 2024. Cela signifie une diminution de 30% ou plus.

Exemple :

- Mois disponibles en 2025 : Jan à Juin
- Moyenne Jan–Juin 2024 : 160 kWh
- Moyenne Jan–Juin 2025 : 110 kWh
- Ratio : $110/160 = 0.6875 \rightarrow$ Règle activée

1.3 Règle 3 – Absence Totale de Consommation

Détecter les situations où un compteur électrique n'enregistre quasiment aucune consommation, ce qui peut indiquer un compteur bloqué, un détournement, ou une désactivation non déclarée.

Définition : Comparer la moyenne des consommations mensuelles disponibles en 2025 à un seuil fixe.

Formule :

$$Moyenne_{2025} = \frac{\sum \text{Consommation mensuelle}_{2025}}{\text{Nombre de mois}}$$

Déclenchement : Si la consommation moyenne sur les mois de 2025 (disponibles) est inférieure à 5 kWh, la règle est activée.

Exemple :

- Jan : 4.8 kWh
- Fév : 3.5 kWh
- Mars : 0.0 kWh
- Avril : 1.2 kWh
- Mai : 4.7 kWh
- Juin : 0.5 kWh
- Moyenne = $(4.8 + 3.5 + 0.0 + 1.2 + 4.7 + 0.5)/6 \approx 2.45$ kWh → Règle activée

1.4 Règle 4 – Régularité Extrême (Compteur Possiblement Bloqué)

Identifier des cas de consommation artificiellement stable sur une longue période, ce qui suggère un compteur bloqué, une sous-estimation systématique, ou une fraude par contournement technique.

Cette règle repose sur la détection de comportements anormalement constants dans l'historique de consommation du client. Elle se base sur des indicateurs statistiques simples, robustes, et croisés.

La règle est activée si toutes les conditions suivantes sont réunies sur une période minimale de 6 mois consécutifs.

Condition	Détail	Explication
1. Coefficient de variation (CV)	$CV = \text{écart-type} / \text{moyenne} < 2\%$	Très faible dispersion relative
2. Écart-type	< 5 kWh sur les 6+ mois	Stabilité absolue très élevée
3. Absence de saisonnalité détectable	$\text{Max} - \text{Min} < 10$ kWh	Pas de variation entre été et hiver
4. 4 mois consécutifs $\approx$ même valeur	± 1 kWh d'écart entre eux	Signale une répétition artificielle

Exemple :

- Données de Jan à Juin : [250, 250, 251, 250, 249, 250]

- $CV \approx 0.3\% \rightarrow$ Satisfait
- Écart-type $\approx 0.75 \rightarrow$ Satisfait
- $\text{Max} - \text{Min} = 2 \rightarrow$ Satisfait
- 4 mois consécutifs $\approx 250 \text{ kWh} \rightarrow$ Satisfait
- $\rightarrow$ Règle activée

3.6 Fusion Hybride (Machine Learning + Règles)

L'architecture finale repose sur la combinaison de deux composantes complémentaires :

- le score machine learning ($Score_{ML}$), issu du méta-modèle de stacking ;
- le score règles ($Score_{regles}$), obtenu à partir des règles métier pondérées.

Score Machine Learning

Le score $Score_{ML}$ correspond à la probabilité prédite par le méta-modèle de stacking. Ce dernier intègre les sorties des modèles de base (Random Forest, XGBoost, LightGBM) et les combine via une régression logistique. Cette approche permet de tirer parti des forces spécifiques de chaque algorithme tout en calibrant la sortie finale sous forme de probabilité. Ainsi, le score ML reflète la probabilité estimée qu'un client appartienne à la classe des fraudeurs confirmés, en s'appuyant exclusivement sur les patterns statistiques extraits de l'historique de consommation.

Score Règles Métier

En parallèle, un score règles a été défini sur la base des déclenchements des règles métier (R1 : chutes brutales, R2 : baisses continues, R3 : consommation nulle ou anormalement stable, etc.). Chaque règle a été associée à un coefficient de pondération reflétant à la fois sa pertinence et sa gravité. Le calcul du score règles est donné par la formule :

$$Score_{regles} = \gamma_1 \cdot R_1 + \gamma_2 \cdot R_2 + \gamma_3 \cdot R_3 + \dots$$

où γ_i désigne le poids attribué à la règle i .

Cette pondération est indispensable pour éviter qu'un client soit jugé frauduleux sur la base d'une seule anomalie ponctuelle (par exemple une baisse de consommation due à une absence temporaire ou un départ en vacances). Ainsi, au lieu d'activer directement une alerte dès le déclenchement d'une règle isolée, le système agrège les règles selon leur importance relative. Les coefficients γ_i ont été optimisés par Grid Search afin de minimiser les faux positifs et d'obtenir un score plus robuste et interprétable.

Score Final Hybride

Le score global du système est obtenu par une combinaison linéaire des deux composantes :

$$Score_{final} = \alpha \cdot Score_{ML} + (1 - \alpha) \cdot Score_{regles}$$

Le paramètre α , qui contrôle l'équilibre entre l'influence du modèle statistique et celle des règles métier, a été appris à l'aide d'une régression logistique. Cette calibration permet d'ajuster automatiquement le poids accordé à chaque source d'information, garantissant une fusion optimale entre la détection statistique et l'expertise métier.

Seuil Décisionnel

Pour transformer le score final en décision binaire (fraude / non fraude), un seuil a été fixé. Après expérimentation et optimisation par Grid Search, le seuil optimal a été déterminé à 0.8 :

$$Score_{final} > 0.8 \Rightarrow \text{Le client est considéré comme suspect de fraude.}$$

Cette politique de décision permet d'équilibrer la précision et le rappel, en limitant les faux positifs coûteux tout en maximisant la détection des fraudes avérées.

Chapitre 2

Résultats du système

2.1 Évaluation de la performance

L'évaluation de la performance de la plateforme repose sur plusieurs métriques clés :

- AUC ROC : mesure de la capacité à distinguer fraudeurs et non-fraudeurs.
- Précision : proportion de vraies alertes parmi toutes les alertes générées.
- Rappel (Recall) : capacité à détecter tous les fraudeurs connus.
- F1-Score : compromis entre précision et rappel.

Métrique	Valeur	Interprétation
AUC ROC	0,942	Très bonne capacité à distinguer fraudeurs/non-fraudeurs
Précision	30,4%	Faible proportion de vrais positifs parmi les alertes
Rappel (Recall)	70,3%	Bon taux de détection des fraudeurs connus
F1-Score	42,4%	Compromis entre précision et rappel, améliorable

TABLE 2.1 – Métriques de performance de la plateforme

Le système montre une excellente capacité de distinction entre fraudeurs et non-fraudeurs, mais la précision faible indique un nombre important de faux positifs. Le rappel élevé souligne une bonne détection des fraudeurs connus.

Chapitre 3

Conclusion et Perspectives

3.1 Synthèse des travaux

Au cours de ce stage, j'ai développé un système hybride de détection de fraudes pour la consommation d'eau et d'électricité, intégrant à la fois des règles métiers basées sur l'expertise terrain et un modèle de Machine Learning avancé (Positive-Unlabeled Learning + Stacking).

Les principales contributions de ce projet sont les suivantes :

- Conception d'un pipeline complet : prétraitement des données, feature engineering professionnel, détection automatique, visualisation des alertes et génération de rapports.
- Développement et intégration de règles métiers pondérées, reflétant la gravité des anomalies (chutes brutales, baisses continues, régularité extrême).
- Mise en œuvre de PU Learning pour créer un dataset fiable avec positifs confirmés et négatifs fiables.
- Modélisation avec Stacking combinant Random Forest, XGBoost et LightGBM, suivi d'une régression logistique pour fusionner scores ML et règles.
- Gestion du déséquilibre des classes via `class_weight` et techniques comme SMOTE/ADASYN.
- Évaluation complète du système avec métriques (Precision, Recall, F1-Score, ROC-AUC, PR-AUC) et visualisations (confusion matrix, courbes ROC et PR, feature importance et SHAP values).
- Déploiement d'un pipeline opérationnel avec retraining mensuel et recalibration automatique des seuils.

Ce projet a permis de créer une plateforme robuste et explicable, capable de détecter efficacement les fraudeurs sur un dataset d'environ 27 000 clients.

3.2 Perspectives d'amélioration

Plusieurs améliorations sont envisagées pour renforcer le système :

- Développement d'une application mobile pour les équipes de terrain, permettant la validation directe des cas détectés par le système.
- Préparation à la montée en charge pour traiter un volume beaucoup plus important de clients (plus d'un million). Cela nécessitera la mise en place d'une architecture Big Data robuste, combinant Spark pour le traitement distribué, Kafka pour le streaming en temps réel et Airflow pour l'orchestration des workflows. L'objectif est de construire un pipeline ETL automatisé et scalable, capable de collecter, traiter et analyser en continu le flux massif de données. Ce pipeline pourra s'exécuter automatiquement chaque mois, identifier les fraudes de manière proactive et générer des rapports détaillés envoyés directement aux responsables de l'entreprise.
- Optimisation du modèle pour réduire les faux positifs, par exemple en améliorant le PU Learning, en testant de nouvelles architectures de stacking ou en affinant les règles métiers.
- Ajout de fonctionnalités supplémentaires pour le suivi des anomalies sur le long terme et la génération de rapports analytiques détaillés.